PK1 TMO

ИУ5-65Б Коновалов И. Н.

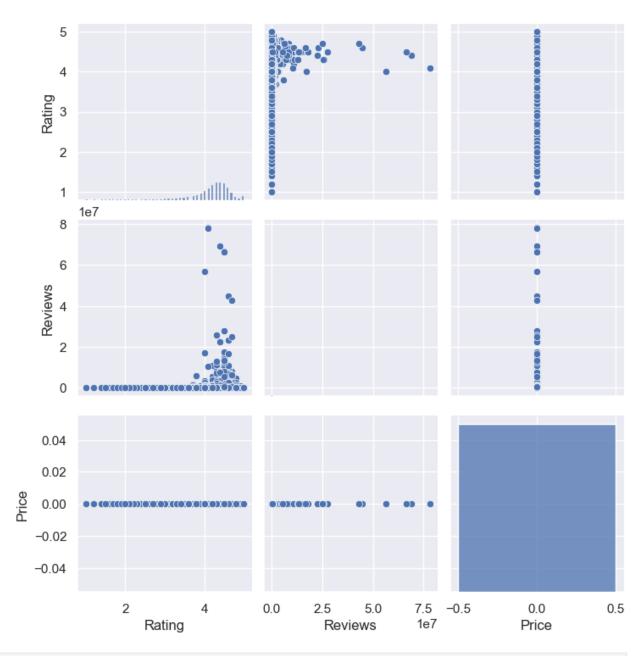
Вариант 7

Задача N°1. Для заданного набора данных проведите корреляционный анализ. В случае наличия пропусков в данных удалите строки или колонки, содержащие пропуски. Сделайте выводы о возможности построения моделей машинного обучения и о возможном вкладе признаков в модель. Для набора данных построить "парные диаграммы".

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
data = pd.read csv("./googleplaystore.csv", sep=',')
data.head()
                                                  App
                                                              Category
Rating
      Photo Editor & Candy Camera & Grid & ScrapBook ART AND DESIGN
4.1
1
                                  Coloring book moana ART AND DESIGN
3.9
2 U Launcher Lite - FREE Live Cool Themes, Hide ... ART AND DESIGN
4.7
3
                                Sketch - Draw & Paint ART AND DESIGN
4.5
               Pixel Draw - Number Art Coloring Book ART AND DESIGN
4
4.3
  Reviews
           Size
                    Installs
                              Type Price Content Rating \
0
      159
            19M
                     10,000+
                               Free
                                        0
                                                Everyone
                    500,000+
1
      967
            14M
                               Free
                                        0
                                                Everyone
2
    87510
           8.7M
                  5,000,000+
                               Free
                                        0
                                                Everyone
3
   215644
            25M
                 50,000,000+
                               Free
                                        0
                                                    Teen
                                        0
      967
           2.8M
                    100,000+
                               Free
                                                Everyone
                      Genres
                                   Last Updated
                                                        Current Ver \
                Art & Design
                                January 7, 2018
                                                               1.0.0
1
   Art & Design; Pretend Play
                              January 15, 2018
                                                               2.0.0
2
                Art & Design
                                 August 1, 2018
                                                               1.2.4
3
                Art & Design
                                   June 8, 2018
                                                 Varies with device
     Art & Design;Creativity
                                  June 20, 2018
    Android Ver
   4.0.3 and up
```

```
1 4.0.3 and up
2 4.0.3 and up
3
    4.2 and up
    4.4 and up
# Преобразовываем значения в колонке Reviews в float, если это
возможно, иначе удаляем строку
data['Reviews'] = data['Reviews'].apply(lambda x: float(x) if
str(x).isdigit() else None)
# Преобразовываем значения в колонке Price в float, если это возможно,
иначе удаляем строку
data['Price'] = data['Price'].apply(lambda x: float(x) if
str(x).isdigit() else None)
# Удаляем строки, в которых Reviews или Price имеют значение None
data = data.dropna(subset=['Reviews', 'Price'])
data.head()
                                                App
                                                           Category
Rating \
      Photo Editor & Candy Camera & Grid & ScrapBook ART AND DESIGN
4.1
1
                                Coloring book moana ART AND DESIGN
3.9
2 U Launcher Lite - FREE Live Cool Themes, Hide ... ART AND DESIGN
4.7
3
                               Sketch - Draw & Paint ART AND DESIGN
4.5
4
               Pixel Draw - Number Art Coloring Book ART AND DESIGN
4.3
   Reviews Size
                      Installs
                               Type
                                     Price Content Rating \
0
      159.0
                      10,000+
             19M
                               Free
                                        0.0
                                                  Evervone
1
      967.0
             14M
                      500,000+
                               Free
                                        0.0
                                                 Everyone
2
   87510.0 8.7M
                    5,000,000+
                               Free
                                        0.0
                                                 Everyone
3
                  50,000,000+
  215644.0
            25M
                               Free
                                        0.0
                                                     Teen
                      100,000+
     967.0
            2.8M
                               Free
                                       0.0
                                                 Everyone
                                 Last Updated
                      Genres
                                                      Current Ver \
               Art & Design
                              January 7, 2018
                                                            1.0.0
0
1
  Art & Design; Pretend Play January 15, 2018
                                                            2.0.0
2
                               August 1, 2018
                                                            1.2.4
               Art & Design
                                 June 8, 2018 Varies with device
3
               Art & Design
                                June 20, 2018
    Art & Design; Creativity
   Android Ver
0 4.0.3 and up
1 4.0.3 and up
```

```
4.0.3 and up
3
     4.2 and up
4
     4.4 and up
data.info()
<class 'pandas.core.frame.DataFrame'>
Index: 10040 entries, 0 to 10840
Data columns (total 13 columns):
 #
     Column
                     Non-Null Count
                                      Dtype
- - -
     -----
 0
     App
                     10040 non-null
                                      object
 1
     Category
                     10040 non-null
                                      object
 2
                                      float64
     Rating
                     8719 non-null
 3
     Reviews
                     10040 non-null
                                      float64
 4
     Size
                     10040 non-null
                                      object
 5
     Installs
                     10040 non-null
                                      object
 6
     Type
                     10039 non-null
                                      object
 7
     Price
                     10040 non-null
                                      float64
 8
                     10040 non-null
     Content Rating
                                      object
 9
                     10040 non-null
     Genres
                                      object
 10
    Last Updated
                     10040 non-null
                                      object
 11
     Current Ver
                     10034 non-null
                                      object
                     10039 non-null
    Android Ver
 12
                                      object
dtypes: float64(3), object(10)
memory usage: 1.1+ MB
data.describe()
                                     Price
            Rating
                         Reviews
                                   10040.0
       8719.000000
                    1.004000e+04
count
          4.186203
                    4.786134e+05
                                       0.0
mean
                                       0.0
std
          0.512338 3.039342e+06
min
          1.000000 0.000000e+00
                                       0.0
25%
          4.000000 4.500000e+01
                                       0.0
50%
          4.300000 2.963500e+03
                                       0.0
75%
          4.500000 6.667825e+04
                                       0.0
          5.000000 7.815831e+07
                                       0.0
max
sns.pairplot(data)
<seaborn.axisgrid.PairGrid at 0x2b193cf10>
```

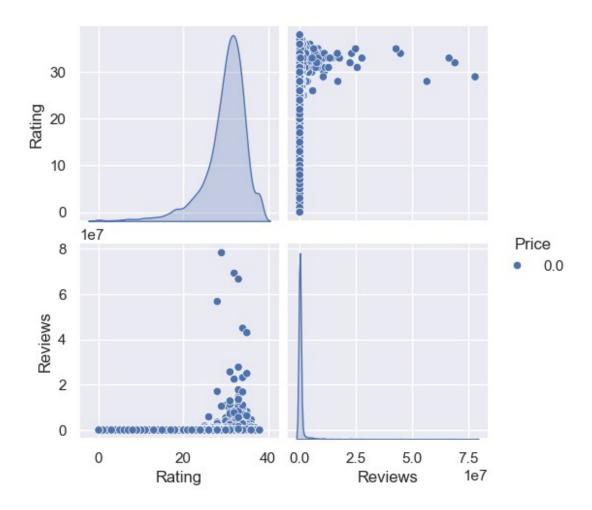


```
[3.300e+01, 1.140e+02, 0.000e+00],
       [3.300e+01, 4.745e+03, 0.000e+00]])
data enc = pd.DataFrame(data=cat enc oe, index=data.index,
columns=["Rating", "Reviews", "Price"])
data enc.head()
   Rating
           Reviews
                     Price
0
     29.0
             159.0
                       0.0
1
     27.0
             706.0
                       0.0
2
     35.0
            3761.0
                       0.0
3
     33.0
            4370.0
                       0.0
     31.0 706.0
                       0.0
data enc["Price"].unique()
array([0.])
# Удаляем колонки Reviews и Price из data enc перед объединением
data_enc = data_enc.drop(columns=['Reviews', 'Price'])
# Объединяем data enc с колонками Reviews и Price из data
data enc = data enc.join(data[["Reviews"]])
data enc = data enc.join(data[["Price"]])
# Выводим результат
data enc
       Rating
                Reviews
                          Price
         29.0
                   159.0
                            0.0
         27.0
1
                   967.0
                            0.0
2
         35.0
                87510.0
                            0.0
3
         33.0 215644.0
                            0.0
4
         31.0
                   967.0
                            0.0
         33.0
                    38.0
                            0.0
10836
10837
         38.0
                     4.0
                            0.0
10838
          NaN
                     3.0
                            0.0
10839
         33.0
                   114.0
                            0.0
10840
         33.0 398307.0
                            0.0
[10040 \text{ rows } x \text{ 3 columns}]
corr matrix = data enc.corr()
corr matrix
           Rating
                              Price
                     Reviews
Rating
         1.000000
                    0.072914
                                NaN
         0.072914
                    1.000000
                                NaN
Reviews
Price
              NaN
                         NaN
                                NaN
```

heatmap = sns.heatmap(corr_matrix, annot=True)



pair_plot = sns.pairplot(data_enc, hue="Price")
plt.show()



На основании корреляционного анализа можно сделать выводы:

- Корреляция между признаками почти отсутствует
- Нельзя выделять влияние чего-либо ввиду недостатка категориальных признаков.
- Придется создавать новые признаки на основе имеющихся